

### 2.6.5) Test de la validité "globale" de la régression:

Une régression linéaire simple ( $Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$ ) est valide, ou significative si  $\beta_1 \neq 0$

Le tableau ANOVA obtenu en (2.5.3) peut être utilisé pour tester:

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

avec la statistique de Fisher

$$F = \frac{MSR}{MSE} = \frac{SSR/1}{SSE/(n-2)}$$

Sous  $H_0$ , on a que  $F \sim F(1, n-2)$

On rejette donc  $H_0$  au niveau  $100 \times (1-\alpha)\%$  si

$$F > F_{\alpha}(1, n-2)$$

Remarque: En régression linéaire simple SEULEMENT (= pas vrai en reg. multiple), le test F est équivalent au test t pour  $\beta_1 = 0$ :

$$\begin{aligned} F &= \frac{SSR/1}{SSE/(n-2)} = \frac{SSR}{\hat{\sigma}^2} = \frac{SSR}{S^2} = \frac{\sum_{t=1}^n (\hat{Y}_t - \bar{Y})^2}{S^2} \\ &= \frac{\sum_{t=1}^n (\hat{\beta}_0 + \hat{\beta}_1 X_t - \hat{\beta}_0 - \hat{\beta}_1 \bar{X})^2}{S^2} = \frac{\hat{\beta}_1^2 \times \sum_{t=1}^n (X_t - \bar{X})^2}{S^2} \end{aligned}$$

$$\Rightarrow F = \frac{\hat{\beta}_1^2}{\frac{s^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

$$= \frac{(\hat{\beta}_1 - 0)^2}{\hat{\text{Var}}(\hat{\beta}_1)}$$

$$= t^2$$

exemple: Soit le tableau ANOVA suivant:

Source	SS	d.l	MS	F
Régression	48.845	1	48.845	9.249
Erreur	63.374	12	5.281	
Total	112.219	13		

Vérifier la validité de la régression à l'aide du test F

$\Rightarrow$  On a que  $F = 9.249$

Or  $F_{0.05}(1, 12) = 4.75$

Puisque  $F > F_{0.05}(1, 12)$ ; on rejette  $H_0$ ; la régression est significative au niveau de confiance 95%.

## 2.7) Prévisions et intervalles de confiance :

On peut utiliser la droite de régression pour faire de types de prévision de  $Y^*$  sachant  $X^*$ :

Type 1: Prévision pour la valeur moyenne (l'espérance de  $Y^*$ ):

$$E(Y^*) = \beta_0 + \beta_1 X^*$$

Type 2: Prévision pour la vraie valeur (réalisation de  $Y^*$ ):

$$Y^* = \beta_0 + \beta_1 X^* + \varepsilon$$

Remarques:

1) Dans les deux types, la prévision est le point sur la droite de régression

$$E(\hat{Y}^*) = \hat{Y}^* = \hat{\beta}_0 + \hat{\beta}_1 X^*$$

2) La prévision est sans biais:


$$E(\hat{\beta}_0 + \hat{\beta}_1 X^*) = E(\hat{\beta}_0) + E(\hat{\beta}_1) X^* = \beta_0 + \beta_1 X^*$$

3) Il y a 2 sources d'erreur dans les prévisions:


I) Parameter risk: Incertitude sur les estimateurs ( $Var(\hat{\beta}_0), Var(\hat{\beta}_1)$ )

II) Process risk: Fluctuations autour de la droite de rég. ( $Var(\varepsilon_i)$ )

# Graphique mont:



## Combinaison des 2 effets :



2.7.1) I.C. pour la prévision de type 1 (valeur moyenne):

\* Aussi appelé I.C. pour la droite de régression

On a que: (sous l'hyp. de la section 2.6.1))

$$(\hat{E}(Y^*) = \hat{\beta}_0 + \hat{\beta}_1 X^*) \sim N(\beta_0 + \beta_1 X^*; \text{Var}(\hat{\beta}_0 + \hat{\beta}_1 X^*))$$

Par conséquent:

$$\frac{(\hat{\beta}_0 + \hat{\beta}_1 X^*) - (\beta_0 + \beta_1 X^*)}{\sqrt{\text{Var}(\hat{\beta}_0 + \hat{\beta}_1 X^*)}} \sim N(0, 1)$$

En remplaçant  $\sigma^2$  par  $S^2$  dans  $\text{Var}(\hat{\beta}_0 + \hat{\beta}_1 X^*)$ ; on a:

$$\frac{(\hat{\beta}_0 + \hat{\beta}_1 X^*) - (\beta_0 + \beta_1 X^*)}{\sqrt{\hat{\text{Var}}(\hat{\beta}_0 + \hat{\beta}_1 X^*)}} \sim t(n-2)$$

Ainsi, un I.C. au niveau  $100 \times (1 - \alpha)\%$  pour la valeur moyenne est:

$$\boxed{(\hat{\beta}_0 + \hat{\beta}_1 X^*) \pm t_{\frac{\alpha}{2}, (n-2)} \times \sqrt{\hat{\text{Var}}(\hat{\beta}_0 + \hat{\beta}_1 X^*)}}$$

$$\begin{aligned}
 \text{Or, } \text{Var}(\hat{\beta}_0 + \hat{\beta}_1 X^*) &= \text{Var}(\bar{Y} - \bar{Y} + \hat{\beta}_0 + \hat{\beta}_1 X^*) \\
 &= \text{Var}(\bar{Y} - (\hat{\beta}_0 + \hat{\beta}_1 \bar{X}) + \hat{\beta}_0 + \hat{\beta}_1 X^*) \\
 &= \text{Var}(\bar{Y} + \hat{\beta}_1 (X^* - \bar{X})) \\
 &= \text{Var}(\bar{Y}) + (X^* - \bar{X})^2 \text{Var}(\hat{\beta}_1) \\
 &= \frac{\sigma^2}{n} + (X^* - \bar{X})^2 \times \frac{\sigma^2}{\sum_{t=1}^n (X_t - \bar{X})^2} \\
 &= \sigma^2 \left( \frac{1}{n} + \frac{(X^* - \bar{X})^2}{\sum_{t=1}^n (X_t - \bar{X})^2} \right)
 \end{aligned}$$


D'où:

$$\widehat{\text{Var}}(\hat{\beta}_0 + \hat{\beta}_1 X^*) = S^2 \left( \frac{1}{n} + \frac{(X^* - \bar{X})^2}{\sum_{t=1}^n (X_t - \bar{X})^2} \right)$$

$\Rightarrow$  l'I.C est donc:

$$(\hat{\beta}_0 + \hat{\beta}_1 X^*) \pm t_{\frac{\alpha}{2}, (n-2)} \times \sqrt{S^2 \times \left( \frac{1}{n} + \frac{(X^* - \bar{X})^2}{\sum_{t=1}^n (X_t - \bar{X})^2} \right)}$$

Remarque:



1) Plus  $X^*$  s'éloigne de  $\bar{X}$ , plus l'I.C. est large (puisque l'incertitude augmente)

2) Les limites de l'intervalle sont des "hyperboles" centrées en  $(\bar{X}, \bar{Y})$ .

3) Cet I.C. peut être appelé: - I.C. pour la valeur moyenne  
- I.C. pour la droite de régression.  
- I.C. pour la tendance.

(\*)

4) Dans ce type de I.C., on tient seulement compte du parameter risk

## 2.7.2) I.C. pour la prévision de type 2 (vraie valeur):

\* Aussi appelé. I.C. pour les points... les réalisations de  $y^*$

Par obtenir un I.C. pour la vraie valeur de  $y^*$ ; il faut tenir compte du ~~parameter risk~~ (...  $\text{var}(\hat{\beta}_i)$ ) ET du process risk (...  $\text{var}(\varepsilon_i)$ ). Process risk

On considère donc: (de manière équivalente à 2.7.1)

$$\frac{y^* - \hat{y}^*}{\sqrt{\text{Var}(y^* - \hat{y}^*)}} \sim N(0,1)$$

En remplaçant  $\sigma^2$  par  $s^2$  dans  $\text{Var}(y^* - \hat{y}^*)$ ; on a:

$$\frac{\hat{y}^* - \hat{y}^*}{\sqrt{\hat{\text{Var}}(y^* - \hat{y}^*)}} \sim t(n-2)$$

Ainsi; un I.C. au niveau  $100 \times (1-\alpha)\%$  pour la vraie valeur de  $y^*$  est:

$$\hat{y}^* \pm t_{\frac{\alpha}{2}}(n-2) \times \sqrt{\hat{\text{Var}}(y^* - \hat{y}^*)}$$

Or,  $\text{Var}(y^* - \hat{y}^*) = \text{Var}(y^*) + \text{Var}(\hat{y}^*)$  ... par hypothèse

$$= \underbrace{\sigma^2}_{\text{Process risk}} + \underbrace{\sigma^2 \left( \frac{1}{n} + \frac{(x^* - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)}_{\text{Parameter risk}}$$



D'où : 
$$\widehat{\text{Var}}(y^* - \hat{y}^*) = s^2 \left( 1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

L'I.C. est donc :

$$\left( \hat{\beta}_0 + \hat{\beta}_1 x^* \right) \pm t_{\frac{\alpha}{2}}(n-2) \times \sqrt{s^2 \times \left( 1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)}$$

exemple (Logiciel R) :

Il est possible d'obtenir le résultats des formules de (2.7.1) et (2.7.2) directement en R.

~~fit~~  $\leftarrow \text{lm}(y \sim x)$

Par obtenir l'I.C. de type 1 :

`predict(fit, interval="confidence")`

• I.C. pour tous les  
•  $x$  dans les  
observations

`predict(fit, interval="confidence", newdata=x.star)`

• I.C. par un  
vecteur  $x^* = x.star$

Par obtenir l'I.C. de type 2 :

`predict(fit, interval="prediction", newdata=x.star)`

• I.C. par un  
vecteur  $x^* = x.star$

## Chapitre 3: Régression multiple:

Il n'est pas rare que plus d'une variable soit nécessaire pour expliquer un phénomène

ex1: 
$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

$\downarrow$   
Revenu  
(salarié)
 $\downarrow$   
Sécurité
 $\downarrow$   
Expérience

De manière générale, la régression multiple considère le modèle:

$$Y_t = \beta_0 + \beta_1 \times X_{t,1} + \beta_2 \times X_{t,2} + \dots + \beta_p \times X_{t,p} + \varepsilon_t$$

pour  $t=1, \dots, n$ .

- $n$  observations
- $p$  variables exogènes ( $X_1, \dots, X_p$ )
- $(p+1)$  paramètres à estimer ( $\beta_0, \beta_1, \dots, \beta_p$ )

### 3.0) Quelques éléments d'algèbre matricielle - Vecteurs et matrices aléatoires:

Soient  $X_1, \dots, X_n$  des v.a. On définit le vecteur aléatoire  $X$  suivant

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix}_{n \times 1}$$

On définit le vecteur espérance de la façon suivante:

$$E(X) = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_n) \end{bmatrix}_{n \times 1}$$

et la matrice de variance-covariance

$$\text{Var}(X) = E \left( \underbrace{(X - E(X))(X - E(X))^{\text{transposée}}}_{\text{Produit matriciel!}} \right) = \begin{bmatrix} \text{Var}(X_1) & \dots & \text{Cov}(X_1, X_n) \\ \vdots & & \vdots \\ \text{Cov}(X_n, X_1) & \dots & \text{Var}(X_n) \end{bmatrix}_{n \times n}$$

Théorème 1: Soit  $X$ , un vecteur aléatoire et  $A$  une matrice de constantes tel que:

$$X = X_{n \times 1} \text{ et } A = A_{p \times n}$$

alors

$$E(AX) = A E(X)$$

et

$$\text{Var}(AX) = A \text{Var}(X) A'$$

example: •  $A = \begin{bmatrix} 1 \\ 1 \end{bmatrix}_{2 \times 1} = [1, 1]_{1 \times 2}$

•  $X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}_{2 \times 1}$

Intuitivement:

$\Rightarrow A X = X_1 + X_2 \Rightarrow E(AX) = E(X_1 + X_2) = E(X_1) + E(X_2)$

•  $Var(AX) = Var(X_1 + X_2)$   
 $= Var(X_1) + Var(X_2) + 2Cov(X_1, X_2)$

Matriciellement:

•  $E(AX) = A \times E(X) = \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} E(X_1) \\ E(X_2) \end{bmatrix} = E(X_1) + E(X_2) \Rightarrow ok$

•  $Var(AX) = A Var(X) A' = \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) \\ Cov(X_1, X_2) & Var(X_2) \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

$= \begin{bmatrix} Var(X_1) + Cov(X_1, X_2) & (Cov(X_1, X_2) + Var(X_2)) \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

$= Var(X_1) + Var(X_2) + 2Cov(X_1, X_2) \Rightarrow ok$

~~11/11~~  
 Remu ici  
 28-07-2020