

En pratique, il est d'usage d'utiliser la méthode de Newton-Raphson pour maximiser numériquement $l(\beta)$.

Pour ce faire, on pose $\hat{\beta}^{(k)}$, le vecteur contenant les valeurs estimées pour β après la k^{e} itération de l'algorithme.

En supposant que l'algorithme ait convergé après l'itération $(i+1)$, alors on a que:

$$\frac{\partial}{\partial \beta} l(\hat{\beta}^{(i+1)}) = 0$$

ou encore que:



$$S(\hat{\beta}^{(i+1)}) = 0$$

; où $S(\cdot)$ est appelé "vecteur score" et est donné par:

$$S(\beta) = \begin{bmatrix} \frac{\partial}{\partial \beta_0} l(\beta) \\ \frac{\partial}{\partial \beta_1} l(\beta) \\ \vdots \\ \frac{\partial}{\partial \beta_p} l(\beta) \end{bmatrix}_{(p+1) \times 1}$$

Pour obtenir un algorithme permettant d'obtenir un estimateur récursivement (à partir de $\hat{\beta}^{(i)}$), il faut développer $S(\hat{\beta}^{(i+1)})$ autour de $\hat{\beta}^{(i)}$ à l'aide d'une série de Taylor:

$$(*) \quad S(\hat{\beta}^{(i+1)}) = S(\hat{\beta}^{(i)}) + \left[\frac{\partial}{\partial \beta} S(\hat{\beta}^{(i)}) \right] (\hat{\beta}^{(i+1)} - \hat{\beta}^{(i)})$$

$$(*) + (\Delta) \Rightarrow S(\hat{\beta}^{(i)}) + \frac{\partial S(\hat{\beta}^{(i)})}{\partial \beta} (\hat{\beta}^{(i+1)} - \hat{\beta}^{(i)}) = 0$$

ou encore ...

$$S(\hat{\beta}^{(i)}) + \left(-I(\hat{\beta}^{(i)}) \right) (\hat{\beta}^{(i+1)} - \hat{\beta}^{(i)}) = 0$$

où

$I(\beta)$ est appelée matrice d'information de Fisher et est donnée par:

$$I(\beta) = \begin{bmatrix} \frac{\partial^2}{\partial \beta_0^2} l(\beta) & \frac{\partial^2}{\partial \beta_0 \partial \beta_1} l(\beta) & \dots & \frac{\partial^2}{\partial \beta_0 \partial \beta_p} l(\beta) \\ \vdots & \vdots & & \vdots \\ \frac{\partial^2}{\partial \beta_1 \partial \beta_0} l(\beta) & \frac{\partial^2}{\partial \beta_1 \partial \beta_1} l(\beta) & \dots & \frac{\partial^2}{\partial \beta_1 \partial \beta_p} l(\beta) \\ \vdots & \vdots & & \vdots \\ \frac{\partial^2}{\partial \beta_p \partial \beta_0} l(\beta) & \frac{\partial^2}{\partial \beta_p \partial \beta_1} l(\beta) & \dots & \frac{\partial^2}{\partial \beta_p \partial \beta_p} l(\beta) \end{bmatrix}_{(p+1) \times (p+1)}$$

Ainsi:

$$S(\hat{\beta}^{(i)}) = I(\hat{\beta}^{(i)}) \left(\hat{\beta}^{(i+1)} - \hat{\beta}^{(i)} \right)$$

→

$$I^{-1}(\hat{\beta}^{(i)}) S(\hat{\beta}^{(i)}) = \hat{\beta}^{(i+1)} - \hat{\beta}^{(i)}$$

⇒

$\hat{\beta}^{(i+1)}$	$=$	$\hat{\beta}^{(i)}$	$+$	$I^{-1}(\hat{\beta}^{(i)})$	$S(\hat{\beta}^{(i)})$
<div style="border-top: 1px solid black; width: 100%; margin-bottom: 5px;"></div> Vecteur de param. mis à jour		<div style="border-top: 1px solid black; width: 100%; margin-bottom: 5px;"></div> Ancien vecteur de param.		<div style="border-top: 1px solid black; width: 100%; margin-bottom: 5px;"></div> Produit matriciel entre l'inverse de la matrice de Fisher et le vecteur score	

4.4.3) Validation "global" du modèle avec la "DÉVIANCE" :

En réécrivant la fonction de vraisemblance $l(\beta)$ comme suit :

$$\begin{aligned} l(\beta) &= \sum_{i=1}^n \ln \left(f_Y(y_i) \right) \\ &= \sum_{i=1}^n \ln \left(f_Y(y_i; \mu_i) \right) \text{ où } \mu_i = g^{-1}(x_i; \beta) \\ &= l(\underline{y}, \underline{\mu}) \end{aligned}$$

... on peut définir la statistique de déviance $D(\beta)$ comme :

$$D(\beta) = 2 \times \left(\underbrace{l(\underline{y}, \underline{y})}_{\substack{\text{"Log vrais"} \\ \text{sous un} \\ \text{modèle} \\ \text{parfait}}} - \underbrace{l(\underline{y}, \underline{\mu})}_{\substack{\text{"Log vrais"} \\ \text{du modèle} \\ \text{obtenu}}} \right)$$

On remarque que dans le cas de la famille exponentielle, on aura :

$$D(\beta) = 2 \times \sum_{i=1}^n \left\{ y_i \cdot x (\theta(y_i) - \theta(\mu_i)) - b(\theta(y_i)) + b(\theta(\mu_i)) \right\}$$

Ainsi:

(1) Loi Normale.

$$D(\beta) = 2 \times \sum_{i=1}^n \left\{ y_i (y_i - \mu_i) - \frac{y_i^2}{2} + \frac{\mu_i^2}{2} \right\}$$

$$= \sum_{i=1}^n \left\{ 2y_i^2 - 2\mu_i y_i - y_i^2 + \mu_i^2 \right\}$$

$$= \sum_{i=1}^n \left\{ y_i^2 - 2\mu_i y_i + \mu_i^2 \right\}$$

$$= \sum_{i=1}^n (y_i - \mu_i)^2$$

$$= \sum_{i=1}^n \hat{\epsilon}_i^2$$

$$= \text{SSE} !$$

Conclusion:

Dans le cas de la loi normale, la déviance est égale à SSE

De fait, $D(\beta)$ constitue une généralisation de SSE qui sera valide avec toutes les sous-cas de la famille exponentielle !

(2) Loi de Poisson:

$$D(\beta) = 2 \times \sum_{i=1}^n \left\{ y_i \times \ln\left(\frac{y_i}{\mu_i}\right) - (y_i - \mu_i) \right\}$$

$\neq \text{SSE!}$

(3) Binomiale (m_i, μ_i):

$$D(\beta) = 2 \times \sum_{i=1}^n \left\{ y_i \times \ln\left(\frac{y_i}{\mu_i}\right) + (m_i - y_i) \times \ln\left(\frac{m_i - y_i}{m_i - \mu_i}\right) \right\}$$

$\neq \text{SSE!}$

(4) Gamma:

$$D(\beta) = 2 \times \sum_{i=1}^n \left\{ -\ln\left(\frac{y_i}{\mu_i}\right) + \frac{y_i - \mu_i}{\mu_i} \right\}$$

$\neq \text{SSE!}$

(5) Inverse Gaussienne:

$$D(\beta) = \sum_{i=1}^n \frac{(y_i - \mu_i)^2}{\mu_i^3 / y_i}$$

$\neq \text{SSE}$

Conclusion: On retombe sur SSE uniquement pour la loi normale.
Dans les autres cas, on a une mesure plus générale!

4.4.4) Validation "local" du modèle avec des tests d'hypothèses et intervalles de confiance:

I) Tests d'hypothèse très général:

On introduit ici une version généralisée des tests de Fisher précédents introduits au chapitre 3.

Hypothèses à considérer: (très similaire à celle de 3.2.3!)

H_0 : Un modèle réduit (noté M_0) qui est un sous-modèle de M_1 (modèle plus complet!) est statistiquement acceptable

H_1 : On doit utiliser le modèle plus complet (noté M_1).

Pour tester H_0 contre H_1 , on utilise la statistique suivante:

$$\chi^2_{\text{OBS}} = D(\hat{\beta}_{H_0}) - D(\hat{\beta}_{H_1})$$

$$= 2 \times \left(\ell(\hat{\beta}_{H_1}) - \ell(\hat{\beta}_{H_0}) \right)$$

... et on rejette H_0 au niveau de confiance $100 \times (1 - \alpha) \%$ si

$$\chi^2_{\text{OBS}} \geq \chi^2_{\alpha} \left(\begin{array}{c} \# \text{paramètres} \\ \text{dans } M_1 \end{array} - \begin{array}{c} \# \text{paramètres} \\ \text{dans } M_0 \end{array} \right)$$

II) Intervalles de confiance:

Selon la théorie du maximum de vraisemblance, on a que la loi asymptotique (lorsque $n \rightarrow \infty$) de $\hat{\beta}$ est une loi normale multi-dimensionnelle:

$$\hat{\beta}_{(p+1) \times 1} \xrightarrow{n \rightarrow \infty} N_{p+1} \left(\beta; \text{Var}(\hat{\beta}) \right)$$

avec

$$\text{Var}(\hat{\beta}) = I^{-1}(\hat{\beta}) \quad ; \quad \text{Borne inférieure de Cramer-Rao !}$$

Ainsi, un intervalle de confiance au niveau $100 \times (1-\alpha)\%$ pour β_i est donné par:

$$\hat{\beta}_i \pm Z_{1-\frac{\alpha}{2}} \times \sqrt{[\text{Var}(\hat{\beta})]_{iH, iH}}$$

4.5) Modèle de régression normale: (un retour!)

Sachant maintenant les résultats plus généraux des GLM, il est intéressant de retravailler les concepts de la régression multiple!

Dans ce cas, on a que:

$$(Y_i | X_i) \sim N(\mu_i, \sigma^2);$$

avec

$$\mu_i = X_i \beta \Rightarrow g(x) = x \quad \left(\begin{array}{l} \text{fonction de} \\ \text{lien identité!} \end{array} \right)$$

Et donc:

$$l(\beta) = \sum_{i=1}^n \ln(f_{Y_i}(y_i))$$

$$= \underbrace{-\frac{1}{2}}_{\text{signe négatif!}} \sum_{i=1}^n \left\{ \ln(2\pi\sigma^2) + \frac{1}{\sigma^2} (y_i - X_i \beta)^2 \right\}$$

cte p/r β

• Remarque: Ici, maximiser $l(\beta)$ revient à minimiser $\sum_{i=1}^n (y_i - X_i \beta)^2 = \text{SSE!}$

Par conséquent:

$$S(\beta) = \frac{\partial}{\partial \beta} \ell(\beta) = ?$$

On cherche le j^{e} élément de ce vecteur $S(\beta)$:

$$\begin{aligned} [S(\beta)]_j &= \frac{\partial}{\partial \beta_j} \ell(\beta) = + \frac{2}{\sigma^2} \sum_{i=1}^n (y_i - X_i \beta) X_{i,j} \\ &= + \frac{1}{\sigma^2} \left(\sum_{i=1}^n X_{i,j} y_i - \left(\sum_{i=1}^n X_{i,j} X_{i,j} \right) \beta \right) \\ &= \frac{1}{\sigma^2} \left(X_j' Y - X_j' X \beta \right) \end{aligned}$$

Ainsi, on déduit que:

$$S(\beta) = \frac{1}{\sigma^2} \left(X' Y - X' X \beta \right)$$

↑↑↑
Jef
19-11-2012