

Et donc:

$$I(\beta) = -\frac{\partial^2}{\partial \beta^2} l(\beta) = -\frac{\partial}{\partial \beta} S(\beta) = ?$$

On cherche l'élément (j, k) de cette matrice $I(\beta)$:

$$\begin{aligned} [I(\beta)]_{j,k} &= -\frac{\partial^2}{\partial \beta_j \partial \beta_k} l(\beta) = -\frac{\partial}{\partial \beta_k} \left(\frac{\partial}{\partial \beta_j} l(\beta) \right) \\ &= -\frac{\partial}{\partial \beta_k} ([S(\beta)]_j) \end{aligned}$$

$$= +\frac{1}{\sigma^2} \sum_{i=1}^n X_{i,j} \times X_{i,k}$$

$$= \frac{1}{\sigma^2} \begin{pmatrix} X_i' & X_j \end{pmatrix}$$

Ainsi, on déduit que:

$$I(\beta) = \frac{1}{\sigma^2} (X'X)$$

En appliquant maintenant l'algorithme de Newton-Raphson de (4.4.2); on a donc :

$$\hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + \mathbf{I}^{-1}(\hat{\beta}^{(i)}) S(\hat{\beta}^{(i)})$$

$$\Rightarrow \hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + \left[\frac{1}{\sigma^2} (\mathbf{X}'\mathbf{X}) \right]^{-1} \frac{1}{\sigma^2} (\mathbf{X}'\mathbf{Y} - \mathbf{X}'\mathbf{X}\hat{\beta}^{(i)})$$

$$\Rightarrow \hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + \sigma^2 (\mathbf{X}'\mathbf{X})^{-1} \frac{1}{\sigma^2} (\mathbf{X}'\mathbf{Y} - (\mathbf{X}'\mathbf{X})\hat{\beta}^{(i)})$$

$$\Rightarrow \hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y} - (\mathbf{X}'\mathbf{X})^{-1} (\mathbf{X}'\mathbf{X})\hat{\beta}^{(i)}$$

$$\Rightarrow \boxed{\hat{\beta}^{(i+1)} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y} \quad \nabla}$$

Conclusion intéressante:

L'approche GLM basée sur la méthode du maximum de vraisemblance et utilisant l'algorithme de Newton-Raphson donne le même résultat pour $\hat{\beta}$ que l'approche "régression multiple" basée sur la minimisation de la distance quadratique

Remarque sur la validation globale et locale du modèle sous la loi normale:

Tel que vu au point (i) de la section (4.4.3),

$$D(\hat{\beta}) \stackrel{\text{Loi Normale}}{=} SSE = \sum_{i=1}^n \hat{\epsilon}_i^2 = \text{Somme de } U(n, 1) \text{ au carré!} \\ \sim \chi^2(n-p+1)$$

Ainsi, la statistique χ^2_{obs} est donnée par:

$$\chi^2_{\text{obs}} = D(\beta_{H_0}) - D(\beta_{H_1})$$

$$= SSE(M_0) - SSE(M_1)$$

Or, puisque

$$\begin{aligned} SSE(M_0) &\sim \chi^2(n - (p_{H_0} + 1)) \\ \text{et} \\ SSE(M_1) &\sim \chi^2(n - (p_{H_1} + 1)) \end{aligned}$$

... on peut dire que tester si

$$\chi^2_{\text{obs}} \geq \chi^2_{\alpha} \left(\underbrace{[n - (p_{H_0} + 1)] - [n - (p_{H_1} + 1)]}_{p_{H_1} - p_{H_0}} \right)$$

... reviens à tester si:

$$F^* = \frac{[SSE(M_0) - SSE(M_1)] / [p_{H_1} - p_{H_0}]}{SSE(M_1) / (n - p_{H_1})} \geq \bar{F}_{\alpha}(p_{H_1} - p_{H_0}, n - p_{H_1})$$

↓ Différence dans le # de paramètres M_0 et M_1

... soit le test de Fisher partiel de (3.2.3).

4.6) Modèle de régression logistique:

Contexte motivant l'utilisation de ce modèle:

Phénomène dichotomique (c-a-d: Y_i peut prendre seulement 2 valeurs ... 0 ou 1!)

ex: • Est-ce que l'assuré i (avec caract. X_i) va avoir des sinistres?

• Est-ce que ce même assuré va renouveler ~~sa~~ sa police avec nous?

• Est-ce qu'un individu ayant les caractéristiques X_i va décéder ou non dans la prochaine année?

• etc !

Remarque: De façon pratique, il est d'usage de définir $Y_i \in \{0, 1\}$

Dans ce cas, on a que:

$$(Y_i | X_i) \sim \text{Bernoulli}(\pi_i),$$

avec

$$g(\pi_i) = X_i \beta$$

Puisque $\pi_i \in]0, 1[$ (π_i est une probabilité) et que $X_i \beta \in \mathbb{R}$, il faut choisir $g(\cdot)$ telle que :

$$g :]0, 1[\rightarrow \mathbb{R}.$$

Bien que plusieurs candidats peuvent satisfaire cette condition, il est d'usage d'utiliser une fonction appelée "logit" dans ce contexte:

$$g(x) = \text{logit}(x) \equiv \ln\left(\frac{x}{1-x}\right).$$

Conséquences:

$$g(\pi_i) = X_i \beta$$

$$\Rightarrow \text{logit}(\pi_i) = X_i \beta$$

$$\Rightarrow \ln\left(\frac{\pi_i}{1-\pi_i}\right) = X_i \beta$$

... et donc on peut exprimer π_i comme suit:

$$\frac{\pi_i}{1-\pi_i} = e^{X_i \beta}$$

$$\Rightarrow \frac{1-\pi_i}{\pi_i} = \frac{1}{e^{X_i \beta}}$$

$$\Rightarrow \frac{1}{\pi_i} - 1 = \frac{1}{e^{X_i \beta}}$$

$$\Rightarrow \frac{1}{\pi_i} = 1 + \frac{1}{e^{X_i \beta}}$$

$$\Rightarrow \pi_i = \frac{1}{1 + \frac{1}{e^{X_i \beta}}}$$

$$\Rightarrow \boxed{\pi_i = \frac{e^{X_i \beta}}{1 + e^{X_i \beta}}}$$

(93)

Interprétations:

(1)

$$\ln\left(\frac{\pi_i}{1-\pi_i}\right) = X_i \beta$$

$$\Rightarrow \ln\left(\frac{\Pr(Y_i=1|X_i)}{\Pr(Y_i=0|X_i)}\right) = X_i \beta$$

... le "log du rapport de cote" est "linéaire"

(2) β_0 : le "log du rapport de cote" lorsque tous les variables explicatives X_i sont = 0.

(3) β_j : Si X_{ij} augmente de une unité (alors que les autres variables explicatives sont fixes), alors le "log du rapport de cote" augmente de β_j unité pour l'individu i .

Sous la méthode du maximum de vraisemblance, on a :

$$l(\beta) = \sum_{i=1}^n \ln \left(\Pr(Y_i = y_i | X_i) \right)$$

$$= \sum_{i=1}^n \ln \left(\pi_i^{y_i} \times (1 - \pi_i)^{1-y_i} \right)$$

$$= \sum_{i=1}^n \left(y_i \ln \pi_i + (1 - y_i) \ln (1 - \pi_i) \right)$$

$$= \sum_{i=1}^n \left(y_i \ln \left(\frac{e^{X_i \beta}}{1 + e^{X_i \beta}} \right) + (1 - y_i) \ln \left(\frac{1}{1 + e^{X_i \beta}} \right) \right)$$

$$= \sum_{i=1}^n \left(y_i \ln(e^{X_i \beta}) - y_i \ln(1 + e^{X_i \beta}) - (1 - y_i) \ln(1 + e^{X_i \beta}) \right)$$

$$= \sum_{i=1}^n \left(y_i \times (X_i \beta) - \ln(1 + e^{X_i \beta}) \right)$$

Pas conséquent;

$$S(\beta) = \frac{\partial}{\partial \beta} \ell(\beta) = ?$$

On cherche le j^{e} élément de ce vecteur $S(\beta)$:

$$\begin{aligned} [S(\beta)]_j &= \frac{\partial}{\partial \beta_j} \ell(\beta) \\ &= \sum_{i=1}^n X_{ij} y_i - X_{ij} \times \frac{e^{X_i \beta}}{1 + e^{X_i \beta}} \\ &= \sum_{i=1}^n X_{ij} \left(y_i - \frac{e^{X_i \beta}}{1 + e^{X_i \beta}} \right) \\ &= X_j' (Y - M(X_j \beta)) \end{aligned}$$

où $M(X_j \beta) = \begin{bmatrix} \frac{e^{X_1 \beta}}{1 + e^{X_1 \beta}} \\ \vdots \\ \frac{e^{X_n \beta}}{1 + e^{X_n \beta}} \end{bmatrix}$

Ainsi, on déduit que:

$$S(\beta) = X' (Y - M(X\beta))$$

(96)

Et donc que:

$$I(\beta) = -\frac{\partial^2}{\partial \beta^2} l(\beta) = -\frac{\partial}{\partial \beta} S(\beta) = ?$$

On cherche l'élément (j, k) de cette matrice $I(\beta)$:

$$[I(\beta)]_{j,k} = -\frac{\partial^2}{\partial \beta_j \partial \beta_k} l(\beta) = -\frac{\partial}{\partial \beta_k} \left(\frac{\partial}{\partial \beta_j} l(\beta) \right) = -\frac{\partial}{\partial \beta_k} [S(\beta)]_j$$

$$= \sum_{i=1}^n X_{ij} \times X_{ik} \left(\frac{e^{X_i \beta} (1 + e^{X_i \beta}) - (e^{X_i \beta})^2}{(1 + e^{X_i \beta})^2} \right)$$

$$= \sum_{i=1}^n X_{ij} \times X_{ik} \left(\frac{e^{X_i \beta}}{(1 + e^{X_i \beta})^2} \right)$$

$$= \sum_{i=1}^n X_{ij} \times X_{ik} \times w_i \quad ; \text{ où } w_i = \frac{e^{X_i \beta}}{(1 + e^{X_i \beta})^2}$$

Ainsi, on déduit que

$$I(\beta) = X' W X \quad ; \text{ avec}$$

$$W = \begin{bmatrix} w_1 & 0 & \dots & 0 \\ 0 & w_2 & \dots & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & \dots & w_n \end{bmatrix}_{n \times n}$$

26-11-2012