

En appliquant l'algorithme de Newton-Raphson, on a :

$$\hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + \mathbf{I}^{-1}(\hat{\beta}^{(i)}) S(\hat{\beta}^{(i)})$$

$$\Rightarrow \hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' (\mathbf{Y} - \mathbf{M}(\mathbf{X} \hat{\beta}^{(i)}))$$

Multiplier par  $\mathbf{I}$

$$\Rightarrow \hat{\beta}^{(i+1)} = \mathbf{I} \hat{\beta}^{(i)} + (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' \mathbf{I} (\mathbf{Y} - \mathbf{M}(\mathbf{X} \hat{\beta}^{(i)}))$$

$$\Rightarrow \hat{\beta}^{(i+1)} = (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} (\mathbf{X}' \mathbf{W} \mathbf{X}) \hat{\beta}^{(i)} + (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' \mathbf{W} \mathbf{W}^{-1} (\mathbf{Y} - \mathbf{M})$$

$$\Rightarrow \hat{\beta}^{(i+1)} = [(\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' \mathbf{W}] \underbrace{\left[ \mathbf{X} \hat{\beta}^{(i)} + \mathbf{W}^{-1} (\mathbf{Y} - \mathbf{M}) \right]}_{\mathbf{Z}^{(i)} : \text{transformation sur } \mathbf{Y}'}$$

$$\Rightarrow \boxed{\hat{\beta}^{(i+1)} = (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' \mathbf{W} \mathbf{Z}^{(i)}}$$

Remarque:

L'algorithme itératif permettant d'obtenir l'estimateur  $\hat{\beta}$  peut être vu comme une succession d'estimations de régressions linéaires de  $\mathbf{Z}^{(i)}$  sur  $\mathbf{X}$ , pondérées par  $\mathbf{W}$ .

(98)

Formule de déviance - régression logistique :

$$D(\beta) = 2 \times \sum_{i=1}^n \left\{ y_i \times \ln \left( \frac{y_i}{\pi_i} \right) + (1 - y_i) \times \ln \left( \frac{1 - y_i}{1 - \pi_i} \right) \right\};$$

où

$$\pi_i = \frac{e^{x_i \beta}}{1 + e^{x_i \beta}}$$

Test d'hypothèse général :

$$\chi^2_{\text{OBS}} = D(\beta_{H_0}) - D(\beta_{H_1})$$

Intervalle de confiance au niveau  $100 \times (1 - \alpha)\%$  pour  $\beta_i$  :

$$\hat{\beta}_i \pm Z_{1 - \frac{\alpha}{2}} \times \sqrt{\left[ (X' W X)^{-1} \right]_{i+1, i+1}}$$

## 4.7) Régression de Poisson:

(99)

Contexte motivant // Utilisation de ce modèle:

Phénomène où la v.a.  $Y$  est positive et discrète ( $Y_i \in \{0, 1, 2, \dots\}$ ).

ex: - Nombre de sinistre d'un assuré au cours de la prochaine année

- Nombre de défauts de fabrication d'un produit

⋮

Dans ce cas, on postule que:

$$(Y_i | X_i) \sim \text{Poisson}(\lambda_i) \quad \lambda_i = E(Y_i | X_i)$$

avec

$$g(\lambda_i) = X_i \beta$$

Puisque  $\lambda_i \in [0, \infty[$  (non-négatif) et que  $X_i \beta \in \mathbb{R}$ , il faut utiliser une fonction  $g(\cdot)$  telle que:

$$g: [0, \infty[ \rightarrow \mathbb{R}$$



Bien que plusieurs candidats peuvent satisfaire cette condition, il est d'usage d'utiliser la fonction logarithmique dans le contexte de la régression de Poisson:

$$g(x) = \ln(x).$$

Conséquences:

$$g(\lambda_i) = \underline{X}_i \beta$$

$$\Rightarrow \ln(\lambda_i) = \underline{X}_i \beta$$

$$\Rightarrow \lambda_i = e^{\underline{X}_i \beta}$$

... en conclusion, sous cette spécification, on a que:

$$(Y_i | \underline{X}_i) \sim \text{Poisson}(e^{\underline{X}_i \beta})$$

... et puisque  $\underline{X}_i \beta = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_p X_{ip}$ , on a:

$$(Y_i | \underline{X}_i) \sim \text{Poisson}(e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}})$$

$$\Rightarrow (Y_i | \underline{X}_i) \sim \text{Poisson}(e^{\beta_0} \times e^{\beta_1 X_{i1}} \times \dots \times e^{\beta_p X_{ip}})$$

↓ Modèle multiplicatif!

Interpretations:

- (1)  $\ln(\lambda_i) = X_i \beta$  ... le "log de l'espérance" est linéaire
- (2)  $\beta_0$ : Lorsque toutes les variables explicatives  $X_i$  sont = 0, alors l'espérance de  $Y_i$  est  $e^{\beta_0}$ .
- (3)  $\beta_i$ : Si  $X_{ij}$  augmente de une unité (abrs que les autres variables explicatives restent fixes), alors l'espérance de  $Y_i$  est multiplié par  $e^{\beta_i}$ .

Sous la méthode du maximum de vraisemblance, on a que :

$$l(\beta) = \sum_{i=1}^n \ln(\Pr(Y_i = y_i | X_i))$$

$$= \sum_{i=1}^n \ln\left(\frac{e^{-\lambda_i} \lambda_i^{y_i}}{y_i!}\right)$$

$$= \sum_{i=1}^n \left( y_i \ln \lambda_i - \lambda_i - \ln(y_i!) \right)$$

$$= \sum_{i=1}^n \left( y_i \times X_i \beta - e^{X_i \beta} - \ln(y_i!) \right)$$

Par conséquent,

$$S(\beta) = \frac{\partial}{\partial \beta} l(\beta) = ?$$

On cherche le  $j^{\text{e}}$  élément du vecteur  $S(\beta)$ :

$$[S(\beta)]_j = \frac{\partial}{\partial \beta_j} l(\beta)$$

$$= \sum_{i=1}^n (y_i x_{ij} - x_{ij} e^{x_i \beta})$$

$$= \sum_{i=1}^n x_{ij} (y_i - e^{x_i \beta})$$

$$\equiv X_j' (Y - M(X_j \beta))$$

où

$$M(X_j \beta) = \begin{bmatrix} e^{x_{1j} \beta} \\ e^{x_{2j} \beta} \\ \vdots \\ e^{x_{nj} \beta} \end{bmatrix}$$

Et donc:

$$S(\beta) = X' (Y - M(X \beta))$$

Et donc

$$I(\beta) = \frac{-\partial^2}{\partial \beta^2} l(\beta) = -\frac{\partial}{\partial \beta} S(\beta)$$

On cherche l'élément  $(j, k)$  de cette matrice  $I(\beta)$ :

$$[I(\beta)]_{j,k} = \frac{-\partial^2}{\partial \beta_j \partial \beta_k} l(\beta) = -\frac{\partial}{\partial \beta_k} \left( \frac{\partial}{\partial \beta_j} l(\beta) \right)$$

$$= -\frac{\partial}{\partial \beta_k} [S(\beta)]_j$$

$$= \sum_{i=1}^n X_{ij} \times X_{ik} e^{X_i \beta}$$

$$= \sum_{i=1}^n X_{ij} \times X_{ik} \times w_i \quad ; \quad \text{où } w_i = e^{X_i \beta}$$

Ainsi, on déduit que:

$$I(\beta) = X' W X \quad ; \quad \text{avec}$$

$$W = \begin{bmatrix} w_1 & 0 & 0 & \dots & 0 \\ 0 & w_2 & 0 & \dots & 0 \\ 0 & 0 & w_3 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & w_n \end{bmatrix}_{n \times n}$$



En utilisant une méthode similaire à celle qui a été appliquée pour le cas de la régression logistique, on peut montrer que l'algorithme de Newton-Raphson suivant:

$$\hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + I^{-1}(\hat{\beta}^{(i)}) S(\hat{\beta}^{(i)})$$

... peut aussi être simplifié sous la forme:

$$\hat{\beta}^{(i+1)} = (X'WX)^{-1} X'WZ^{(i)};$$

où

$$Z^{(i)} = X\hat{\beta}^{(i)} + W^{-1}(Y - M(X, \hat{\beta})).$$



## 4.8) Autres notions importantes avec les GLM:

### 4.8.1) Autres distributions:

La procédure illustrée aux sections (4.5), (4.6) et (4.7) s'applique à toutes les distributions de la famille exponentielle.

Les cas les plus célèbres sont:

#### A) Loi Binomiale négative:

- Permet d'obtenir une variance plus grande que la moyenne (ce qui est impossible avec la loi de Poisson).

- Fonction de log-vraisemblance:

$$(Y_i | X_i, \oplus_i) \sim \text{Poisson}(\lambda_i \times \oplus_i)$$

où  $\ln(\lambda_i) = X_i \beta \Rightarrow \lambda_i = e^{X_i \beta}$

et  $\oplus_i \sim \Gamma(\alpha, \alpha) \Rightarrow E(\oplus_i) = 1$   
 $\text{Var}(\oplus_i) = 1/\alpha$

Note: Si  $\alpha \rightarrow \infty$ , alors NegBin  $\rightarrow$  Poisson !!!

$$\Pr(Y_i = y_i | X_i) = \int_0^{\infty} \frac{e^{-\lambda_i \oplus} (\lambda_i \oplus)^{y_i}}{y_i!} \times \frac{\alpha^\alpha \oplus^{\alpha-1} e^{-\alpha \oplus}}{\Gamma(\alpha)} d\oplus$$

$$\rightarrow P(Y_i = y_i | X_i) = \frac{\alpha^\alpha \lambda^{y_i}}{\Gamma(y_i+1) \Gamma(\alpha)} \int_0^\infty \theta^{(y_i+\alpha)-1} e^{-(\alpha+\lambda_i)\theta} d\theta$$

$$= \frac{\alpha^\alpha \lambda^{y_i}}{\Gamma(y_i+1) \Gamma(\alpha)} \times \frac{\Gamma(y_i+\alpha)}{(\alpha+\lambda_i)^{y_i+\alpha}}$$

$$= \frac{\Gamma(y_i+\alpha)}{\Gamma(y_i+1) \Gamma(\alpha)} \left( \frac{\alpha}{\alpha+\lambda_i} \right)^\alpha \left( \frac{\lambda_i}{\alpha+\lambda_i} \right)^{y_i}$$

$$\bullet l(\beta) = \sum_{i=1}^n \ln \left( P(Y_i = y_i | X_i) \right)$$

$$\bullet S(\beta) = \frac{\partial}{\partial \beta} l(\beta)$$

$$\bullet I(\beta) = \frac{\partial^2}{\partial \beta^2} l(\beta)$$

$$\bullet \hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + I^{-1}(\hat{\beta}^{(i)}) S(\hat{\beta}^{(i)})$$

111  
03-12-2022