

Remarque - Test de surdispersion:

H_0 : Pas de surdispersion (\Rightarrow la variance de Y est égale à l'espérance de Y)

H_1 : Il y a de la surdispersion

$$\begin{aligned} \Rightarrow \text{Var}(Y) &= E(\text{Var}(Y|\Phi)) + \text{Var}(E(Y|\Phi)) \\ &= (E(\lambda \times \Phi) + \text{Var}(\lambda \times \Phi)) \\ &= \lambda \times 1 + \lambda^2 \times 1/\alpha \\ &= \lambda \times \left(1 + \frac{1}{\alpha}\right) \end{aligned}$$

Procédure:

- (1) Obtenir $l_{\text{poisson}}(\beta)$ avec une régression Poisson
- (2) Obtenir $l_{\text{NB}}(\beta)$ avec une régression Binomiale négative
- (3) Calculer $\chi^2_{\text{OBS}} = 2 \times (l_{\text{NB}}(\beta) - l_{\text{poisson}}(\beta))$
- (4) On rejette H_0 au niveau de confiance $100 \times (1 - \alpha)\%$

si

$$\chi^2_{\text{OBS}} \geq \chi^2_{1-2\alpha}(1)$$

↑
car, le test est "unilatéral"
et non bilatéral

B) Loi Gamma:

- Permet de modéliser des cas où Y est continue, mais non-négative (ex: sévérité des sinistres)

- Fonction de log-vraisemblance:

$$f_{Y_i|X_i}(y_i) = \frac{(\alpha/\mu_i)^\alpha y_i^{\alpha-1} e^{-(\alpha/\mu_i)y_i}}{\Gamma(\alpha)}$$

; où

$$\bullet \ln(\mu_i) = \tilde{X}_i \beta \quad \begin{array}{l} \text{lien log} \\ \Rightarrow \end{array} \quad \mu_i = e^{\tilde{X}_i \beta}$$

$$\bullet \frac{1}{\mu_i} = \tilde{X}_i \beta \quad \begin{array}{l} \text{lien inverse} \\ \Rightarrow \end{array} \quad \mu_i = \frac{1}{\tilde{X}_i \beta}$$

$$\Rightarrow E(Y_i|X_i) = \mu_i = g^{-1}(\tilde{X}_i \beta)$$

$$\Rightarrow \text{Var}(Y_i|\tilde{X}_i) = \frac{\mu_i^2}{\alpha}$$

$$\bullet l(\beta) = \sum_{i=1}^n \ln(f_{Y_i|X_i}(y_i))$$

$$\bullet S(\beta) = \frac{\partial}{\partial \beta} l(\beta)$$

$$\bullet I(\beta) = -\frac{\partial^2}{\partial \beta^2} l(\beta)$$

$$\bullet \hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + I^{-1}(\hat{\beta}^{(i)}) S(\hat{\beta}^{(i)})$$

4.8.2) Algorithme du "Scoring":

Est un algorithme itératif pour estimer les paramètres qui peut parfois être une alternative à l'algorithme de Newton-Raphson.

Pour obtenir l'algorithme du scoring, il faut simplement remplacer $I(\hat{\beta}^{(i)})$ par $F(\hat{\beta}^{(i)})$ dans la formule:

$$\hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + I^{-1}(\hat{\beta}^{(i)}) S(\hat{\beta}^{(i)})$$

du

$$F(\hat{\beta}^{(i)}) = \mathbb{E}_Y \left(I(\hat{\beta}^{(i)}) \right)$$

L'algorithme du scoring s'écrit donc comme:

$$\hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} + F^{-1}(\hat{\beta}^{(i)}) S(\hat{\beta}^{(i)})$$

Remarque: En pratique, il est d'usage d'utiliser cet algorithme pour alléger les formules lorsqu'il reste des termes en " y_i " dans la matrice $I(\hat{\beta}^{(i)})$

NOTE: Dans les cas normal, logistique et Poisson, il n'y a pas de " y_i " dans $I(\hat{\beta}^{(i)})$, mais ce n'est pas le cas avec une loi gamma par exemple, ou bien avec la loi géométrique.

exemple: Loi géométrique

$$(1) \Pr(Y_i = y_i | X_i) = p_i^{y_i-1} \times (1-p_i) ; y_i \in \{1, 2, \dots\}$$

$$(2) \text{Fonction de lien } g(x) = \ln(x-1)$$

$$\Rightarrow \ln(E(Y_i | X_i) - 1) = X_i \beta$$

$$\Rightarrow E(Y_i | X_i) - 1 = e^{X_i \beta}$$

$$\Rightarrow E(Y_i | X_i) = 1 + e^{X_i \beta}$$

$$\Rightarrow \frac{1}{1-p_i} = 1 + e^{X_i \beta}$$

$$\Rightarrow 1-p_i = \frac{1}{1+e^{X_i \beta}}$$

$$\Rightarrow p_i = \frac{e^{X_i \beta}}{1+e^{X_i \beta}}$$

Fonction de log-vraisemblance:

$$\begin{aligned} l(\beta) &= \sum_{i=1}^n \ln(\Pr(Y_i = y_i | X_i)) \\ &= \sum_{i=1}^n \left\{ (y_i - 1) \ln(p_i) + \ln(1-p_i) \right\} \end{aligned}$$

$$= \sum_{i=1}^n \left\{ (y_i - 1) \ln \left(\frac{e^{X_i \beta}}{1 + e^{X_i \beta}} \right) + \ln \left(\frac{1}{1 + e^{X_i \beta}} \right) \right\} \quad (III)$$

$$= \sum_{i=1}^n \left\{ (y_i - 1) [X_i \beta - \ln(1 + e^{X_i \beta})] - \ln(1 + e^{X_i \beta}) \right\}$$

$$= \sum_{i=1}^n \left\{ (y_i - 1) (X_i \beta) - y_i \times \ln(1 + e^{X_i \beta}) \right\}$$

Vecteur score:

$$[S(\beta)]_j = \frac{\partial}{\partial \beta_j} l(\beta) = \sum_{i=1}^n \left\{ (y_i - 1) X_{ij} - y_i \times X_{ij} \frac{e^{X_i \beta}}{1 + e^{X_i \beta}} \right\}$$

= ...

$$= \sum_{i=1}^n \left\{ \frac{y_i}{1 + e^{X_i \beta}} - 1 \right\} \times X_{ij}$$

Matrice d'information de Fisher:

$$[I(\beta)]_{j,k} = \frac{\partial^2 l(\beta)}{\partial \beta_j \partial \beta_k} = \frac{\partial}{\partial \beta_k} \left(\frac{\partial l(\beta)}{\partial \beta_j} \right) = \frac{\partial}{\partial \beta_k} [S(\beta)]_j$$

$$= \sum_{i=1}^n \left\{ y_i \times \left(\frac{e^{X_i \beta}}{1 + e^{X_i \beta}} \right) \times \left(\frac{1}{1 + e^{X_i \beta}} \right) \times X_{ij} \times X_{ik} \right\}$$

... il y a des "y_i" dans I(β) !

Matrice F:

$$\begin{aligned}
 [F(\beta)]_{j,k} &= E_y \left([I(\beta)]_{j,k} \right) \\
 &= E_y \left(\sum_{i=1}^n \left\{ y_i \times \left(\frac{e^{X_i \beta}}{1+e^{X_i \beta}} \right) \times \left(\frac{1}{1+e^{X_i \beta}} \right) \times X_{ij} \times X_{ik} \right\} \right) \\
 &= \sum_{i=1}^n \left\{ E(y_i | X_i) \times \left(\frac{e^{X_i \beta}}{1+e^{X_i \beta}} \right) \times \left(\frac{1}{1+e^{X_i \beta}} \right) \times X_{ij} \times X_{ik} \right\} \\
 &= \sum_{i=1}^n \left\{ \left(\frac{1}{1+p_i} \right) \times \left(\frac{e^{X_i \beta}}{1+e^{X_i \beta}} \right) \times \left(\frac{1}{1+e^{X_i \beta}} \right) \times X_{ij} \times X_{ik} \right\} \\
 &= \sum_{i=1}^n \left\{ (1+e^{X_i \beta}) \left(\frac{e^{X_i \beta}}{1+e^{X_i \beta}} \right) \left(\frac{1}{1+e^{X_i \beta}} \right) \times X_{ij} \times X_{ik} \right\} \\
 &= \sum_{i=1}^n \left(\frac{e^{X_i \beta}}{1+e^{X_i \beta}} \right) \times X_{ij} \times X_{ik} = \sum_{i=1}^n X_{ij} \times w_i \times X_{ik}
 \end{aligned}$$

... plus simple, car non fonction des "y_i".

... F(β) peut donc s'écrire comme suit:

$$F(\beta) = X' W X ; W = \begin{bmatrix} w_1 & 0 & \dots & 0 \\ 0 & w_2 & \dots & 0 \\ & & \ddots & \\ 0 & 0 & \dots & w_n \end{bmatrix}$$

Hilary

4.8.3) Variable "offset" :

(113)

... est une variable explicative dont le " β " est 1.

Utilisation en actuariat :

Modélisation de la fréquence des sinistres à partir de la loi Poisson

exemple :

i	U_i	N_i	X_{i1}	X_{i2}	...	X_{ip}
1	0.5	1	1	1		1
2	1.0	2	1	1		1
3	1.0	0	1	1		1
4	0.25	1	1			1
5	0.05	0		1		1

- U_i : $\frac{1}{2}$ de l'année où l'assuré a obtenu une police en vigueur

\approx les unités d'exposition.

- N_i : Nombre de sinistre de l'assuré i .

Modèle GLM :

$$(N_i | U_i, \underline{X}_i) \sim \text{Poisson}(\lambda_i)$$

$$\lambda_i = U_i \times e^{X_i \beta}$$

Idée sous-jacente à ce modèle:

Un assuré qui a détenu une police en vigueur pendant quelque jours a considérablement moins de chances d'avoir des sinistres qu'un assuré qui a conservé sa police en vigueur pendant toute l'année!

Interprétation:

• $\lambda_i = U_i \times e^{X_i \beta}$: Nombre de sinistre espéré pour l'assuré i .

• $\frac{\lambda_i}{U_i} = e^{X_i \beta}$: Fréquence de sinistre espéré pour l'assuré i

Variable "offset"

$$\begin{aligned}\lambda_i &= U_i \times e^{X_i \beta} \\ &= e^{\ln(U_i)} \times e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}} \\ &= e^{\ln(U_i) + \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}}\end{aligned}$$

... en posant $O_i = \ln(U_i)$, alors on a que:

$$\lambda_i = e^{1 \times O_i + \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}}$$


Ici, O_i est appelé "variable offset" !

4.8.4) Ajout d'une interaction entre 2 variables explicatives:

...si on pense que l'effet combiné de 2 variables explicatives doit être différent de l'addition des effets individuels de ces 2 variables

exemple: Y : Coûts d'assurance auto
 X_1 : Age de l'assuré au carré
 X_2 : Indicateur que l'assuré est un homme


En pratique, on observe souvent la tendance suivante:



Or, il est impossible d'obtenir le graphique précédent avec une structure linéaire de la forme:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2$$

Car le β_2 ne fait qu'induire un effet de translation sur les courbes sans jouer sur l'amplitude:



$$g(E(Y|X_i)) = \begin{cases} \beta_0 + \beta_1 X_1, & \text{si femme} \\ (\beta_0 + \beta_2) + \beta_1 X_1, & \text{si homme} \end{cases}$$

Pour permettre à l'amplitude de varier selon le sexe, il faut ajouter une interaction à la structure linéaire précédente, soit:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 \times X_2$$

Partie "interaction"
entre X_1 et X_2

Ainsi:

$$g(E(Y_i | X_i)) = \begin{cases} \beta_0 + \beta_1 X_1 & , \text{si femme} \\ (\beta_0 + \beta_2) + (\beta_1 + \beta_3) X_1 & , \text{si homme} \end{cases}$$

Remarque importante:

Tout comme le traitement des variables non-numériques, l'ajout d'une interaction ne nécessite que de modifier la matrice schéma X et le vecteur β :

Sans interaction:

$$X = \begin{bmatrix} & X_1 & X_2 \\ 1 & 60 & 0 \\ 1 & 30 & 1 \\ 1 & 20 & 0 \\ \vdots & \vdots & \vdots \end{bmatrix} ; \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}$$

Avec interaction:

$$X = \begin{bmatrix} & X_1 & X_2 & X_3 = X_1 \times X_2 \\ 1 & 60 & 0 & 0 \\ 1 & 30 & 1 & 30 \\ 1 & 20 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix} ; \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix}$$

4.8.5) Analyse des résidus:

(117)

Toute la théorie introduite au chapitre 3 reste valide pour les GLM à l'exception du fait qu'il soit nécessaire de définir un résidu plus général.

Résidus de déviance:

$$\hat{\Sigma}_D = \text{signe}(y_i - \hat{\mu}_i) \times \sqrt{2 \times \left(l(\underline{y}, \underline{y})_i - l(\underline{y}, \underline{\mu})_i \right)}$$

↑ ↑
... les i^e termes
dans la somme de
 $l(\beta)$