

# Exercice 1 - Série 5

①

On reprend les données de l'exemple vu en classe

$$n=20$$

Variables dans le modèle	SSE	SSR
$\emptyset$	10	0
$X_1$	5	5
$X_2$	9	1
$X_3$	8	2
$X_1, X_2$	4	6
$X_1, X_3$	3.9	6.1
$X_2, X_3$	8.5	1.5
$X_1, X_2, X_3$	3.8	6.2

- a) Utiliser le test de Fisher pour tester la validité globale du modèle (niveau=95%)

$$Y_t = \beta_0 + \beta_1 X_{t1} + \beta_2 X_{t2} + \beta_3 X_{t3} + \varepsilon_t$$

- b) Utiliser le test partiel de Fisher pour tester si
- $$H_0: \beta_1 = \beta_2 = 0$$
- $$H_1: \beta_1 \neq 0 \text{ ou } \beta_2 \neq 0$$

dans le modèle  $Y_t = \beta_0 + \beta_1 X_{t1} + \beta_2 X_{t2} + \beta_3 X_{t3} + \varepsilon_t$

- c) Appliquer les algorithmes "forward" et "stepwise" afin de sélectionner un modèle "optimal"

# Solution 1 - Série 5

①

a)  $H_0: \beta_1 = \beta_2 = \beta_3 = 0$

$H_1$ : Au moins un  $\beta_i$  ( $i=1,2,3$ ) est  $\neq 0$ .

$$F = \frac{MSR}{MSE} = \frac{SSR/3}{SSE/(20-(3+1))} = \frac{6.2/3}{3.8/16} = 8.702$$

Puisque  $F > F_{0.05}(3, 16) = 3.24$ , on rejette  $H_0$

$\Rightarrow$  La régression est significative au global

b)  $H_0: \beta_1 = \beta_2 = 0$  ;  $M_0 \equiv Y_t = \beta_3 X_{t3} + \varepsilon_t$

$H_1: \beta_1 \neq 0$  ou  $\beta_2 \neq 0$  ;  $M_1 \equiv Y_t = \beta_0 + \beta_1 X_{t1} + \beta_2 X_{t2} + \beta_3 X_{t3} + \varepsilon_t$

$$F^* = \frac{(8 - 3.8) / ([20 - (1+1)] - [20 - (3+1)])}{3.8 / (20 - (3+1))}$$

$$F^* = \frac{4.2/2}{3.8/16} = 8.842$$

Puisque  $F^* > F_{0.05}(2, 16) = 3.63$ , on rejette  $H_0$

$\Rightarrow$  On rejette le modèle "réduit" ( $Y_t = \beta_0 + \beta_3 X_{t3} + \varepsilon_t$ )

$\Rightarrow$  On ne peut pas exclure "simultanément" les variables  $X_1$  et  $X_2$  du modèle!

## c) Forward:

(2)

1) Début :  $Y_t = \beta_0 + \varepsilon_t$        $SSE = 10$

2) Meilleure variable à ajouter  
(= générant la plus grande diminution du SSE) :

$X_1 \Rightarrow \Delta = 10 - 5 = 5$
$X_2 \Rightarrow \Delta = 10 - 9 = 1$
$X_3 \Rightarrow \Delta = 10 - 8 = 2$

Choix :  $X_1$

3)  $H_0: Y_t = \beta_0 + \varepsilon_t$  ... modèle "réduit"

$H_1: Y_t = \beta_0 + \beta_1 X_{t1} + \varepsilon_t$  ... modèle "augmenté"

$$F^* = \frac{(10 - 5) / 1}{5 / (20 - (1 + 1))} = \frac{5 / 1}{5 / 18} = 18$$

Puisque  $F^* > F_{0.05}(1, 18) = 4.41$ , on rejette  $H_0$

$\Rightarrow$  On accepte  $H_1$

$\Rightarrow$  On préfère le modèle  $Y_t = \beta_0 + \beta_1 X_{t1} + \varepsilon_t$

$\Rightarrow$  On inclut  $X_1$  dans le modèle!

2) Meilleure variable à ajouter:

$X_2 \Rightarrow \Delta = 5 - 4 = 1$
$X_3 \Rightarrow \Delta = 5 - 3.9 = 1.1$

Choix =  $X_3$

3)  $H_0: Y_t = \beta_0 + \beta_1 X_{t1} + \varepsilon_t$

$H_1: Y_t = \beta_0 + \beta_1 X_{t1} + \beta_3 X_{t3} + \varepsilon_t$

$$F^* = \frac{(5-3.9)/1}{3.9/(20-(2+1))} = \frac{1.1/1}{3.9/17} = 4.795 \quad (3)$$

Puisque  $F^* > F_{0.05}(1,17) = 4.45$ , on rejette  $H_0$   
 $\Rightarrow \dots \Rightarrow$  on inclut  $X_3$  dans le modèle

2) Meilleure variable à ajouter :  $X_2$  (seul choix!)

$$3) H_0: Y_t = \beta_0 + \beta_1 X_{t1} + \beta_3 X_{t3} + \varepsilon_t$$

$$H_1: Y_t = \beta_0 + \beta_1 X_{t1} + \beta_2 X_{t2} + \beta_3 X_{t3} + \varepsilon_t$$

$$F^* = \frac{(3.9-3.8)/1}{3.8/(20-(3+1))} = \frac{0.1/1}{3.8/16} = 0.421$$

Puisque  $F^* < F_{0.05}(1,16) = 4.49$ ; on accepte  $H_0$

$\Rightarrow X_2$  n'est pas incluse dans le modèle!

$$\text{Modèle final: } Y_t = \beta_0 + \beta_1 X_{t1} + \beta_3 X_{t3} + \varepsilon_t$$

# Stepwise

(4)

1) Début:  $Y_t = \beta_0 + \varepsilon_t$  ;  $SSE = 10$

2) Meilleure variable à ajouter:  $X_1$

3)  $F^* = \frac{(10-5)/1}{5/18} = 1.8 > F_{0.05}(1, 18) = 4.41 \Rightarrow X_1$  entre ds modèle

4) Pire variable à exclure:  $X_1$  (un seul choix!)

5)  $F^* = \frac{(10-5)/1}{5/18} = 1.8 > F_{0.05}(1, 18) = 4.41 \Rightarrow$  on rejette le modèle "réduit" de  $H_0$ .

$\Rightarrow X_1$  non exclu du modèle

2) Meilleure variable à ajouter:  $X_3$

3)  $F^* = \frac{(5-3.9)/1}{3.9/17} = 4.795 > F_{0.05}(1, 17) \Rightarrow X_3$  entre ds modèle

4) Pire variable à exclure dans le modèle  $Y_t = \beta_0 + \beta_1 X_{t1} + \beta_2 X_{t3} + \varepsilon_t$

$$X_1 \Rightarrow |A| = |3.9 - 8| = 4.1$$

$$X_3 \Rightarrow |A| = |3.9 - 5| = 1.1$$

Choix:  $X_3$

$$F^* = \frac{(5-3.9)/1}{3.9/17} = 4.795 > F_{0.05}(1, 17)$$

$\uparrow$   
 $H_0: Y_t = \beta_0 + \beta_1 X_{t1} + \varepsilon_t$   
 $\downarrow$   
 $H_1: Y_t = \beta_0 + \beta_1 X_{t1} + \beta_2 X_{t3} + \varepsilon_t$

$\Rightarrow$  On rejette  $H_0$ .

$\Rightarrow$  On rejette le modèle "simplifié"  $M_0$

$\Rightarrow$  On ne peut pas exclure  $X_3$

$\Rightarrow$  Modèle final:  $Y_t = \beta_0 + \beta_1 X_{t1} + \beta_3 X_{t3} + \varepsilon_t$  !